BANCO DE DADOS E ARQUITETURA PARA BIG DATA

NOSSA HISTÓRIA

A nossa história inicia com a realização do sonho de um grupo de empresários, em atender à crescente demanda de alunos para cursos de Graduação e Pós-Graduação. Com isso foi criado a nossa instituição, como entidade oferecendo serviços educacionais em nível superior.

A instituição tem por objetivo formar diplomados nas diferentes áreas de conhecimento, aptos para a inserção em setores profissionais e para a participação no desenvolvimento da sociedade brasileira, e colaborar na sua formação contínua. Além de promover a divulgação de conhecimentos culturais, científicos e técnicos que constituem patrimônio da humanidade e comunicar o saber através do ensino, de publicação ou outras normas de comunicação.

A nossa missão é oferecer qualidade em conhecimento e cultura de forma confiável e eficiente para que o aluno tenha oportunidade de construir uma base profissional e ética. Dessa forma, conquistando o espaço de uma das instituições modelo no país na oferta de cursos, primando sempre pela inovação tecnológica, excelência no atendimento e valor do serviço oferecido.

Sumário

INTRODUÇÃO 4

CONTEXTO HISTÓRICO 6

O QUE É O BIG DATA 7

FASES DO PROCESSO DE ANÁLISE DO BIG DATA 10

VANTAGENS DO USO DO BIGA DATA 11

DESAFIOS DA UTILIZAÇÃO DO BIG DATA 14

O QUE É UMA ARQUITETURA DE DADOS 16

ARQUITETURA PARA BIG DATA 17

IMPLANTAÇÃO DE BIG DATA 19

VISÃO FUNCIONAL DO BIG DATA 21

O QUE É PRECISO PARA SE OBTER SUCESSO NA IMPLEMENTAÇÃO DO BIG DATA 23

CONSIDERAÇÕES FINAIS 24

REFERÊNCIAS 26

INTRODUÇÃO

Seu conceito pode ser definido como ferramentas e práticas que gerenciam e analisam grandes volumes de dados de diferentes fontes, em velocidade considerável, buscando agregar as organizações, valor de negócios e maior confiabilidade em relação às decisões a serem tomadas.

Este artigo visa esclarecer a concepção e conceito de Big Data, sua utilização nas organizações, apresentar as tecnologias envolvidas, para que desta maneira as empresas possam utilizar desses recursos, contando com os benefícios de que dispõe para um maior gerenciamento e apoio na tomada de decisões.

Com a popularização da internet e o surgimento de mídias sociais, o número de dados digitais gerados aumentou de forma significativa. Esses dados podem ser classificados em estruturados e não estruturados, com base no seu gerenciamento e armazenamento.

Os dados estruturados são organizados em linhas e colunas, geralmente são encontrados em banco de dados relacionais, são eficientes quanto à recuperação e processamento. Já os dados não estruturados referem-se a dados que não podem ser organizados em linhas e colunas, como vídeos, comentários em redes sociais e e-mails, entre outros.

Geralmente são dados de difícil acesso e recuperação e muitas vezes não dispõem de componentes necessários para identificação de tipo de processamento e interpretação, tornando o seu uso um desafio principalmente em aplicativos empresariais.

Grande parte dos dados digitais gerados atualmente, principalmente através de mídias sociais, os quais vêm despertando o interesse das organizações para serem usados como estratégias de negócio, são do tipo não estruturados.

Esse tipo de dados requer dispositivos de armazenamento e processamento que suportem seu formato e garantam melhor eficiência em suas análises. Diante desta necessidade crescente de armazenar, manipular e analisar de forma rápida e inteligente, grandes volumes de dados não estruturados foi criado o conceito de Big Data.

CONTEXTO HISTÓRICO

Na década de 1940 já se falava em "explosão de dados" e "grandes volumes de dados", porém, foi na década de 1990 que na divulgação de um artigo, a IEEE mencionou o termo “Big Data" pela primeira vez. Em 2001, o termo passou a ser definido pelos 3Vs, de: Volume, Velocidade e variedade. O conceito de Big Data pode ser definido como ferramentas e práticas que gerenciam e analisam grandes volumes de dados, de diferentes fontes, em velocidade considerável, buscando agregar às organizações valor de negócios e maior confiabilidade em relação às decisões a serem tomadas.

Para as organizações aderirem com sucesso a esse novo conceito de análise e gerenciamento de grandes volumes de dados, é recomendado o cumprimento de algumas fases, são elas:

1) aquisição e gravação;
2) limpeza, formatação e validação;
3) integração, agregação e representação;
4) análise e modelagem; e
5) interpretação dos dados.

O cumprimento das fases acima garante maior confiabilidade quanto à utilização do conceito Big Data.

O QUE É O BIG DATA

Big Data são tecnologias e práticas emergentes que possibilitam a seleção, processamento, armazenamento e geração de insights de grandes volumes de dados estruturados e não estruturados de maneira rápida, efetiva e a um custo acessível. Big Data pode ser considerado como um conjunto de dados que cresce exponencialmente e necessita de habilidades além das quais as ferramentas típicas de gerenciamento e processamento de informações dispõem.

Taurion descreve ainda que se trata de "Um conjunto de tecnologias, processos e práticas que permitem às empresas analisarem dados a que antes não tinham acesso e tomar decisões ou mesmo gerenciar atividades de forma muito mais eficiente”. Segundo o autor citado acima "não é teoria ou futurologia, é algo que se encontra agora”.

Big Data pode ser definido também, como um grande data warehouse ou um BI em cima de um data set de terabytes de dados ou também como um volume de dados muito significativo, porém não se trata apenas de volume, mas também de uma variedade imensa de dados não estruturados que precisam ser avaliados e tratados em velocidade adequada para terem valor ao negócio.

De maneira mais simples, resume-se em "Big Data = volume + variedade + velocidade + veracidade, gerando valor". Volume refere-se à quantidade de dados gerados a cada segundo, variedade, porque os dados vêm de diversas fontes (estruturados e não estruturados), velocidade, pois se trata muitas vezes de informações em tempo real, veracidade, porque é necessário que os dados sejam autênticos e façam sentido e, por fim, valor, pois é o que as organizações buscam, ou seja, o retorno dos investimentos.

Com a expansão dos conceitos de Big Data, diversas empresas já estão tomando iniciativas para aderir ao mesmo, porém, sem uma estratégia bem definida, afinal, *"Big Data não é apenas comprar pacotes de tecnologia, mas uma nova maneira de explorar esse imenso volume de dados que circula dentro e fora das empresas"*. Para aderir ao Big Data , as empresas devem estar cientes de que serão embutidas transformações em processos de negócio, fonte de dados, infraestrutura de tecnologia, capacitação e mudanças organizacionais na empresa e em TI.

O conceito de Big Data dispõe de inúmeras vantagens para as organizações, mas a principal vantagem é a identificação das necessidades dos clientes, sendo possível desenvolver estratégias de mercado e apoio a tomada de decisões mais precisas. Contudo, surgem também alguns desafios, como trabalhar com a segurança e confiabilidade dos dados.

Para auxiliar as organizações nos processos relacionados ao Big Data existem ferramentas analíticas como o Hadoop e MapReduce, também banco de dados NoSQL, que estão preparados para armazenar, gerenciar e analisar grandes volumes de dados de diferentes formatos.

O número de dados gerados por meios eletrônicos tem aumentado significativamente com o desenvolvimento da tecnologia. Atualmente são gerados mais dados do que a civilização gerou desde o seu início até o ano de 2003. Com todo este volume de dados surgem possibilidades de análise e gerenciamento, de maneira a gerar informações úteis na tomada de decisão das empresas. Esta nova maneira de armazenar, gerenciar e analisar grandes volumes de dados de diversas fontes, a uma velocidade considerável denomina-se Big Data.

Contudo, a maioria das empresas ainda não tem uma visão clara do conceito Big Data, do seu potencial e de como alavancar esta potencialidade. Bem como, de que a ideia de que Big Data só faz sentido se o valor da análise dos dados compensar o custo de sua coleta, armazenamento e processamento e as questões legais envolvidas.

Dados podem ser caracterizados como uma descrição primária de objetos, eventos, atividades e transações que são gravados, classificados e armazenados, mas não chegam a ser organizados de forma a transmitir algum significado específico. Quando esse conjunto de registros sobre um determinado evento, fato, número, texto ou qualquer mídia que possa ser processada pelo computador, é agrupada, caracterizado e padronizado, transforma-se em informação.

Antes de serem transformados em informação, os dados podem ser divididos em dois grupos, segundo o armazenamento e gerenciamento. No primeiro grupo encontram-se os dados estruturados e no segundo os dados não estruturados.

Os dados estruturados são organizados em linhas e colunas em um formato definido de forma rígida, de modo que os aplicativos possam recuperá-los e processá-los com eficiência. Já os dados não estruturados são os que não podem, ou são difíceis de serem armazenados em linhas e colunas.

Geralmente são de difícil acesso e recuperação e requerem maior espaço e velocidade para armazenamento e gerenciamento. São muitas vezes dados que não dispõem de componentes necessários para identificação de tipo de processamento e interpretação, tornando o seu uso um desafio, principalmente em aplicativos empresariais.

O formato de dados não estruturados corresponde a 80% dos dados corporativos, podendo ser encontrados na forma de e-mails, comentários em redes sociais, vídeos, entre outros.

FASES DO PROCESSO DE ANÁLISE DO BIG DATA

Para que ocorra sucesso com o uso desse novo conceito, é necessário que as organizações sigam algumas fases do processo de Big Data.

A coleta de dados ou aquisição e agravação é a primeira fase do processo de Big Data. Nesse momento devem ser analisados o volume e a variedade dos dados que serão coletados. É necessário que se faça uma limpeza, formatação e validação dos dados coletados, para que sejam eliminados erros, dados incompletos e incoerentes, evitando assim contaminar análises futuras.

Depois disso vem a fase de integração, agregação e representação dos dados obtidos, pois diferentes tipos e formatos de dados devem receber tratamentos específicos. Nesta fase é importante definir categorias de dados e critérios de validação e aceitação, também critérios de segurança variam de acordo com as fontes de dados.

Em seguida encontra-se a fase de análise e modelagem dos dados. Como se trata de dados de diversas fontes para serem analisados, requer conhecimento elevado por parte dos usuários. Aqui entra o "datascientist", um profissional com habilidades em ciência da computação, matemática, estatística e conhecimento de negócio. Esta fase também requer investimentos em pesquisas de novas formas de visualização, que ajudam na melhor interpretação dos dados, que se trata da última fase do pipeline.

VANTAGENS DO USO DO BIGA DATA

Algumas das possíveis vantagens de seu uso são:

Saber exatamente o que os clientes querem, estudando seus hábitos de consumo. O conhecimento das necessidades do cliente faz com que possa ser oferecido ao mesmo exatamente o que deseja, ganhando assim a confiança;

Encontrar potenciais compradores a partir da mensuração em tempo real das redes sociais. O desenvolvimento da tecnologia permite que pessoas de diversas localidades geográficas conheçam o produto e ofertas em tempo real, com isso pode ocorrer expansão nas vendas;

Prevenir possíveis riscos para o negócio graças a análises em tempo real de distintas variáveis do mercado. Pode ser analisado em tempo real tudo o que está ocorrendo no mercado, sendo assim, existe possibilidade de tomar medidas preventivas e antecipatórias em relação a dificuldades e oportunidades;

Observar o que a concorrência está fazendo para desenhar ofertas especiais. Conhecer o concorrente e pensar alternativas para aumentar lucros.

Todas as observações citadas pela SAP dispõem às organizações um diferencial de mercado e vantagem competitiva em relação a seus concorrentes.

As vantagens do Big Data estão relacionadas a dois fatores:

- O efeito dos grandes números, que garante a validade das análises;

A capacidade de adicionar uma multiplicidade de novos vetores de preferência, complementando e enriquecendo a qualidade das análises devido à observação de comportamentos específicos em indivíduos com características similares.

Estes fatores podem ser melhor explicados nos seguintes itens:

- Transformação de dados não estruturados em informação útil para análise sistemática, através de técnicas de Big Data que possibilitam a atribuição de indicadores de “sentimento”. Neste sentido, existem já diversos softwares que classificam os comentários produzidos nas redes sociais de acordo com o teor das mensagens e a sua intensidade;
- Utilização dos dados de forma experimental, correlacionando grandes volumes de dados quantitativos históricos com informação recente, depois de passar pelo processo de estruturação (por exemplo, comentários realizados em blusões) e antecipando assim as expectativas do mercado;
- Segmentação exaustiva dos diversos perfis de consumo, permitindo identificar clusters de clientes e adaptar as abordagens de forma micro segmentadas, sempre que possível em real time (por exemplo, utilização de promoções por georreferencia);
- Aceleração do processo de inovação das empresas, com reflexo na rapidez do desenvolvimento de ideias para novos produtos e serviços e na sua performance esperada, permitindo endereçar não só o desafio de criar ofertas inovadoras como também de gerir de forma proativa todo o customer life cycle – desde a captação à retenção, incluindo mecanismos de aumento de valor e da satisfação dos clientes nas interações realizadas ao longo dos diversos pontos de contato.

O Big Data traz às empresas a grande oportunidade de obtenção da excelência no conhecimento mais adequado e imediato do cliente e do mercado. Essa eficiência está ligada a qualidade das informações integrada aos diversos sistemas corporativos e que os ganhos serão obtidos por aqueles que perceberem o sentido de ampliar a gama das fontes de dados e garantir veracidade e velocidade, bem como a proximidade no relacionamento com seus clientes.

O caminho da obtenção de vantagens competitivas trazidas pelo Big Data é o conhecimento profundo do negócio para perceber e chegar à combinação ideal de dados e informações sobre o cliente e o mercado, que possam favorecer a estratégia, eficácia, aceitação da proposta de valor, prever tendências de consumo e, por fim, alcançar avanços na realização dos objetivos estratégicos da empresa.

DESAFIOS DA UTILIZAÇÃO DO BIG DATA

Para alcançar a efetividade do Big Data é necessário que os benefícios estejam claros e os incentivos alinhados, criando condições de aprofundar técnicas e utilizá-las nas organizações. Alguns dos principais desafios do Big Data são:

Políticas de privacidade, acesso, tratamento e utilização da informação: se por um lado é imprescindível garantir a proteção da privacidade dos clientes, por outro lado só será possível melhorar a qualidade dos dados analisados se estiver garantida o recolhimento sistemático de informação. Mas como garantir que os clientes disponibilizem, por exemplo, informação da sua localização atual? Como conseguir relacionar um determinado cliente com o seu perfil nas redes sociais? O envolvimento dos clientes é crítico porque só dessa forma o ciclo de Big Data ficará completo;

Avanço tecnológico e multidisciplinaridade: à medida que o volume de dados aumenta, maiores são os desafios que se colocam à capacidade de armazenamento e análise. Os principais provedores de tecnologia têm apostado fortemente em novas técnicas de storage, data mining e business intelligence. No entanto, uma maior colaboração com as áreas de negócio e os principais influenciadores em cada indústria será crítica para conseguir adaptar a tecnologia às necessidades imediatas das empresas, sem ter de passar por processos morosos e custosos de implementação;

Orientação para o cliente: apenas percebendo o fim para o qual se destinam os dados é útil aprofundar as metodologias de Big Data. Exceder as expectativas do cliente deverá ser a principal finalidade. Para isso, a organização deverá desenvolver estratégias globais que permitam integrar os modelos de dados com os modelos de relação nos diversos pontos de contato de forma holística e dinâmica, adaptando-se à expectativa de cada cliente a cada momento.

Outro desafio visível em relação ao Big Data é a falta de profissionais qualificados. A EMC Brasil realizou uma pesquisa onde 73% das empresas entrevistadas apontaram a cultura como sendo a maior barreira de lidar com o Big Data. O levantamento destaca que 88% das companhias acreditam que será um desafio capacitar seus trabalhadores para a nova TI.

O QUE É UMA ARQUITETURA DE DADOS

A arquitetura de dados é um daqueles componentes invisíveis, mas que, quando falham, podem comprometer seriamente a performance de uma empresa e seus profissionais.

É como em edifícios físicos que, sem um projeto arquitetônico à altura, têm suas funções mal aproveitadas, ficando sujeitos a problemas.

Este é um mapa mental para visualizar os principais componentes de uma Arquitetura de Big Data:

(Fonte: https://canaltech.com.br/big-data/Visao-geral-da-Arquitetura-de-Big-Data/)

ARQUITETURA PARA BIG DATA

Arquiteturas em Big Data podem fornecer soluções capazes de analisar grande volume de dados em tempo real. Para esta análise utiliza-se banco de dados não relacionais também conhecidos como NoSQL. As tecnologias da Big Data são acessíveis para pequenas e medias empresas, trazendo muitos benefícios.

Os resultados obtidos através destas tecnologias, nos apresentada dados que podem melhor a maneira de relacionamento com os clientes. [Pensando Grande, 2016].

As tecnologias para Big Data oferecem novas oportunidades em análise e compreensão mais aprofundada dos dados. Mapeando os padrões dos dados, sendo estruturados e não estruturados. Para este mapeamento utiliza-se ferramentas com grande poder computacional, e modelo de computação paralela.

Big Data mudou a forma de entender e explorar os dados, pois a análise dos dados é impulsionada a uma investigação não causal. Big Data tem o conceito de ampliar o potencial das analises, mas Big Data não é somente o volume de dados, está também ligada a variedade, ao acesso a outras fontes de dados, esta fonte geralmente é externa, possibilitando assim uma ampliação da visão do contexto.

Para Jill Dyché vice-presidente da SAS Best Pratices, Big Data é mais que apenas um grande volume de dados não estruturados, ele também conclui que as tecnologias que possibilita o processamento e análise, estas tecnologias possibilitam analisar conteúdo de forma rápida. [Davenport 2014].

Para atender a demanda é necessário estabelecer uma arquitetura tecnológica compatível. O momento tecnológico que vivemos permitiu estabelecer formas de armazenar dados não estruturados. Armazenar e recuperar dados não

estruturados exige uma forma diferenciada em relação ao que tem sido feito até então. Um novo padrão de banco de dados foi criado para isto. Eles são chamados de NoSQL (Not Only SQL). E os bons e velhos arquivos texto, imagens, voz, etc. que são armazenados diretamente no sistema operacional voltam a fazer parte do contexto da análise de dados.

Os bancos de dados padrão SQL são amplamente conhecidos no mundo corporativo. Eles facilitaram muito o acesso e disponibilização dos dados nas organizações. Porém, eles foram criados para lidar com dados estruturados. Quando se fala em dados estruturados, o que se quer dizer é que o dado estará formatado para trabalhar com um padrão baseado em linhas e colunas, com uma sintaxe robusta e uma modelagem consistente. Como informado anteriormente, para manipulação de dados não estruturados utiliza-se muitas vezes o próprio sistema de arquivos (Linux e MS Windows, por exemplo).

Os principais componentes desta arquitetura são (mas não se limitam a):

1. Hadoop: plataforma para armazenamento e processamento de um grande volume de dados utilizando hardware simples e que normalmente utilizam clusters para agilizar o acesso e manipulação dos dados;
2. MapReduce: modelo de programação paralela, escalável e que permite a utilização de hardware simples para realizar trabalhos complexos;
3. NoSQL: banco de dados que permite armazenar e recuperar dados com menos restrições do que os bancos de dados relacionais. Possui uma modelagem mais simples e permite aumentar a escalabilidade e disponibilidade do ambiente;
4. SQL: bancos de dados tradicionais que armazenam a maior parte dos dados estruturados nas organizações. Os dados normalmente têm origem em sistemas ERP, SCM (Supply Chain), CRM, etc.;
5. DW: O Data Warehouse é um banco de dados apartado do banco de dados dos sistemas transacionais que são modelados para facilitar a análise de dados para a tomada de decisão.

A utilização de alguns destes componentes em conjunto indica o trabalho em um ambiente de Big Data. Ao se utilizar um dos componentes isoladamente, dificilmente se estará trabalhando com Big Data.

IMPLANTAÇÃO DE BIG DATA

A Visão de Implantação mostra o ambiente onde o sistema será instalado, bem como o software sugerido para sua execução. Os sistemas de big data criados a partir desta arquitetura são implantados em um datacenter, uma nuvem pública ou privada. Os servidores podem ser VMs ou máquinas físicas (bare metal), pois não há significativa perda de performance. Para a criação de provas de conceito é possível utilizar um único servidor desempenhando todas as funções. Neste caso, a performance não pode ser avaliada, porque os recursos computacionais são limitados. Apesar disso, é possível validar se as funcionalidades foram atendidas.

Existem quatro funcionalidades principais previstas na arquitetura, que atendem às demandas dos sistemas de big data. As funcionalidades são: (i) Cluster de Big Data, no qual residem os serviços de Armazenamento e Análise de Dados. O (ii) Servidor de API engloba o serviço de Integração de Dados, enquanto o (iii) Servidor NoSQL engloba o Gerenciamento de Dados. Por fim, o (iv) Storage oferta novamente o serviço de Armazenamento de Dados, com a diferença de que nesta configuração não existe a necessidade do cluster de big data, pois é utilizada a tecnologia de object storage e data lakes, que é uma tendência no mundo do big data.

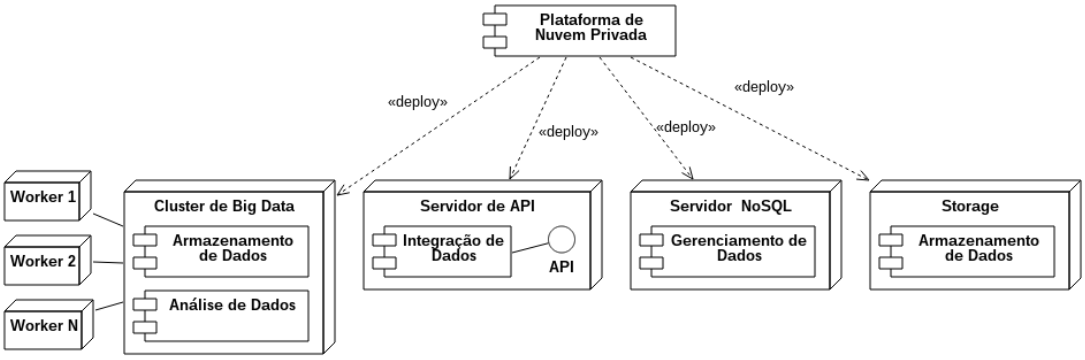

(Fonte: https://blog.marcoreis.net/arquitetura-de-referencia-para-solucoes-de-big-data/)

VISÃO FUNCIONAL DO BIG DATA

A Visão Funcional descreve os usos, os componentes, as interfaces, as entidades externas e as principais interações entre eles, como pode ser visto na figura abaixo.

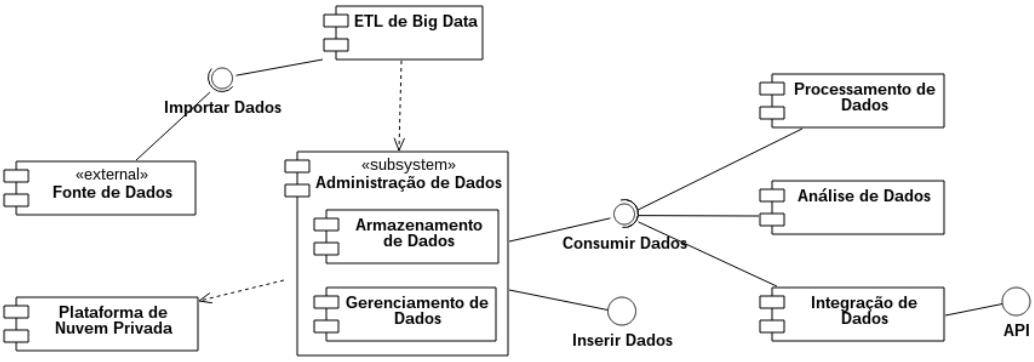

(Fonte: https://blog.marcoreis.net/arquitetura-de-referencia-para-solucoes-de-big-data/)

O componente de Fonte de Dados é uma entidade externa que representa, como o nome sugere, qualquer mecanismo que forneça dados corporativos, e inclui os SGBDRs, os sistemas de arquivos e os web services.

O ETL de Big Data realiza o processamento necessário para converter os dados de seu formato de origem para os formatos suportados pelo mecanismo de armazenamento de big data.

O sub-sistema de Administração de Dados é um componente lógico que envolve dois componentes. O primeiro deles é o serviço de Armazenamento de Dados, responsável por persistir os dados no sistema de arquivos distribuído. O componente de Gerenciamento de Dados é constituído pelo banco de dados NoSQL. Este sub-sistema dispõe de uma interface para que novos registros sejam inseridos sem a necessidade de passar pelo ETL de Big Data. A outra interface permite que os demais componentes consumam diretamente os dados.

O Processamento de Dados é composto pelos mecanismos para processamento batch e tempo real, além de oferecer suporte para a implantação de

programas de big data, como Hadoop e Spark, a partir de seus respectivos frameworks.

O serviço de Integração de Dados é uma funcionalidade presente nas arquiteturas de big data mais recentes. Ele oferece uma API para que entidades externas consumam os dados do sistema. A API é construída a partir de um banco NoSQL e disponibilizada por meio de web services, uma tendência na área de big data e computação em nuvem.

O último serviço é o de Análise de Dados, que combina mecanismos de consulta ad hoc, de estatística e de algoritmos de machine learning. Estas funcionalidades são usadas pelos cientistas de dados e fazem parte de uma área conhecida como big data analytics.

O QUE É PRECISO PARA SE OBTER SUCESSO NA IMPLEMENTAÇÃO DO BIG DATA

O sucesso na construção de uma arquitetura Big Data depende principalmente da clareza do escopo, quais perguntas devem ser respondidas e por consequência o valor a ser gerado, encontrado através dos conhecimentos dos 5Vs, volume, velocidade, variedade, veracidade e valor. Com um crescimento constante no volume de dados da tabela calls, a proposta de uma arquitetura em Big Data e de total coerência, uma vez que este modelo arquitetural consta de um poder computacional muito amplo para tratar grande volume e variedade de dados, além de poder oferecer insight sobre o valor destes dados que antes não eram percebidos.

Oferecendo novas oportunidade de negócios através de analises de Business Intelligence aliadas ao Big Data e outras tecnologias que fazem parte do ecossistema. O ecossistema utilizando tecnologias com o Apache Hadoop, Hadoop MapReduce, Apache HDFS e o Elasticsearch agregam valor fundamental para a arquitetura, a união e a sincronização delas proporciona recursos muito amplos, recursos que atualmente não fazem parte do escopo inicial deste projeto, mais que podem em trabalhos futuros agregar esta arquitetura.

Uma desta tecnologias que vem ser consolidando cada vez mais neste modelo de arquitetura, é o banco NoSQL, com um paradigma diferente do banco de dados relacional, eles propõem maneiras diferentes de armazenamento dos dados, seja no modelo de chavevalor, família de colunas, orientado a documentos e baseado em grafos.

Cada modelo tem suas particularidades para resolver determinados cenários, mas o modelo relacional também tem suas particularidades, não podemos afirmar que um substitui o outro, mais sim que cada um tem seus benéficos, assim cada um é melhor utilizado para atender determinados cenários.

CONSIDERAÇÕES FINAIS

Nesta apostila foi apresentado a arquitetura para sistemas de big data, na qual as análises devem ser feitas preferencialmente em data lakes. Esta é uma tendência que está sendo seguida pelos principais provedores de big data do mercado.

Assim, verificamos que as arquiteturas e frameworks para big data estão se desenvolvendo de acordo com as mudanças na tecnologia e nas demandas de novas soluções para problemas que lidam com uma quantidade crescente de dados. Para tanto, novas alternativas são propostas utilizando processamento distribuído, paralelo e escalável.

Sem uma boa visão e definição de Negócio, é impossível ter uma solução ou mesmo um projeto de Big Data. Saber a questão adequada para um problema de Big Data e vincular esta questão com uma necessidade real do negócio da empresa é fundamental para este tipo de projeto. Identificar oportunidades competitivas envolve conhecer melhor o cliente, o produto, a cadeia de distribuição ou produção, os fornecedores e os competidores. Big Data pode ser uma boa ferramenta para atender este objetivo. Mas sem ter em mente com clareza e precisão onde se quer chegar, fatalmente este tipo de projeto estará fadado ao fracasso.

Outro elemento extremamente importante está no Armazenamento dos Dados (o primeiro dos três Vs de Big Data). O Armazenamento envolve questões que nascem em uma Plataforma Distribuída, passa pelos bancos específicos (NoSQL) e terminam em um ambiente de Tomada de Decisão (representado pelo SQL e Data Warehouse no mapa). Não considero um grande problema. Atualmente há ferramentas que atendem com relativa facilidade esta questão.

A Escalabidade tem a ver com o Volume, mas também envolve a Variedade das origens (o segundo dos Vs) encontrada neste tipo de projeto. E isso se resolve com Processamento Paralelo, Bancos Não-Relacionais (NoSQL) e Cloud Computing. É uma solução técnica. Certamente irá evoluir para facilitar o processo, mas não é algo que deva atemorizar o condutor deste tipo de projeto.

A Coleta e Integração de Dados também é um problema que envolve os dois primeiros Vs. Está relacionado com Cloud Computing, mas encontra seus principais desafios na Ingestão e Limpeza / Tratamento de Dados. Permitam-me a redução conceitual, mas a Ingestão para mim é um ETL de alta complexidade, com inúmeras fontes e com técnicas de solução do problema muito semelhantes, mas, naturalmente, adaptadas ao volume e variedade de dados do Big Data.

A Segurança não está apenas relacionada à questão da Governança e seus acordos para acesso, controle e disseminação dos dados. Está intimamente relacionada à questão Ética. O que é ético fazer com dados que na grande maioria das vezes são públicos? Como uma análise dos dados públicos pode interferir na vida das pessoas? Estas questões precisam de calma e sensatez para que se possa encontrar as respostas.

A Visualização dos Dados envolve o uso e a prática de técnicas estatísticas adequadas para responder às questões de negócio que justificarão o desenvolvimento do projeto. Com estes importantes recursos da matemática, será possível estabelecer Análises de Correlação que utilizam técnicas de Data Mining (mineração de dados) aplicadas em um grande volume de dados.

Por fim, e não menos importante, o uso de técnicas de Análise avançadas, Machine Learning (aprendizagem de máquina) com algoritmos especialmente testados, desenvolvidos e aplicados para modelos de previsão permitem que o terceiro V (Velocidade) atenda às necessidades do negócio. Mostrar estas análises de maneira adequada ao tomador de decisão ou estabelecer visualização para modelos criados é o produto final de um projeto de Big Data.

REFERÊNCIAS

CUKIER, Kenneth. MAYER-SCHONBERGER, Viktor. **“Big data: como extrair volume, variedade e valor da avalanche de informação cotidiana; tradução Paulo Polzonoff Junior”**, Rio de Janeiro, Elsevier. 2013.

FILHO, Osilmar Mendonça Costa, CARDOSO, Marcelo de Castro. **Arquitetura em Big Data para organização de milhões de ligações em uma empresa de Telecom.** Centro Universitário de Anápolis (UniEvangélica) – Anápolis, GO – Brazil.

PODEROSO, Celso. **Big Data – arquitetura do ambiente**. 2014.

REIS, Marcos. **Arquitetura de Referência para Soluções de Big Data**. 2018.

TAURION, Cezar. **“O caos conceitual e os 5 Vs do Big Data”.** 2012.